

Φάση Ε: Model Evaluation & Σύγκριση

Υπεύθυνος: ML Engineer

Μετρικές:

- Accuracy
- Precision / Recall
- F1-Score
- ROC-AUC
- Confusion Matrix

Οπτικοποιήσεις:

1. Confusion Matrix (heatmap)
2. ROC Curve
3. Συγκριτικά bar charts
4. Πίνακας σύγκρισης

```
# Φάση Ε & ΣΤ: Model Evaluation, Σύγκριση & Συμπεράσματα (ΠΛΗΡΗΣ ΚΑΛΥΨΗ + F1-SCORE)
```

```
from pyspark.sql import SparkSession
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.metrics import (accuracy_score, precision_score, recall_score,
                             f1_score, confusion_matrix, roc_curve, auc)

spark =
SparkSession.builder.appName("Evaluation_Metrics_Final").master("local[*]").getOrCreate()

print("Φόρτωση προβλέψεων (Pandas)...")
df_rf = spark.read.parquet("../data/rf_predictions.parquet").toPandas()
df_svm = spark.read.parquet("../data/svm_predictions.parquet").toPandas()
df_nb = spark.read.parquet("../data/nb_predictions.parquet").toPandas()
df_mlp = spark.read.parquet("../data/mlp_predictions.parquet").toPandas()
df_gbt = spark.read.parquet("../data/gbt_predictions.parquet").toPandas()
df_lr = spark.read.parquet("../data/lr_predictions.parquet").toPandas()
df_rf_under = spark.read.parquet("../data/
rf_under_predictions.parquet").toPandas()

# Λεξικό για πλήρη αποθήκευση μετρικών ανά κλάση και συνολικά
metrics_dict = {
    "Model": [],
    "Acc (Total)": [],
    "P (Class 0)": [], "R (Class 0)": [], "F1 (Class 0)": [],
    "P (Class 1)": [], "R (Class 1)": [], "F1 (Class 1)": [],
    "ROC-AUC": []
}
```

```

}

def evaluate_model_full(df, model_name, prob_col="probability"):
    y_true = df['stroke'].values
    y_pred = df['prediction'].values

    # ROC-AUC
    y_prob = np.array([v[1] for v in df[prob_col]]) if prob_col == "probability"
    else np.array([v[1] for v in df[prob_col]])
    fpr, tpr, _ = roc_curve(y_true, y_prob)
    roc_auc = auc(fpr, tpr)

    # Μετρικές ανά κλάση (Precision, Recall, F1)
    # precision_recall_fscore_support επιστρέφει arrays [Class0_score,
    Class1_score]
    precisions, recalls, f1s, _ = precision_recall_fscore_support(y_true, y_pred,
labels=[0, 1], zero_division=0)
    acc = accuracy_score(y_true, y_pred)

    # Προσθήκη στο λεξικό
    metrics_dict["Model"].append(model_name)
    metrics_dict["Acc (Total)"].append(acc)
    metrics_dict["P (Class 0)"].append(precisions[0])
    metrics_dict["R (Class 0)"].append(recalls[0])
    metrics_dict["F1 (Class 0)"].append(f1s[0])
    metrics_dict["P (Class 1)"].append(precisions[1])
    metrics_dict["R (Class 1)"].append(recalls[1])
    metrics_dict["F1 (Class 1)"].append(f1s[1])
    metrics_dict["ROC-AUC"].append(roc_auc)

    cm = confusion_matrix(y_true, y_pred)

    # Εκτύπωση αναλυτικού classification report για να το έχεις στο terminal
    print(f"\n{'='*20} {model_name} {'='*20}")
    print(classification_report(y_true, y_pred, target_names=["Class 0", "Class
1"]))

    return fpr, tpr, roc_auc, cm

# Εκτέλεση αξιολόγησης (7 Μοντέλα)
fpr_rf, tpr_rf, auc_rf, cm_rf = evaluate_model_full(df_rf, "Random Forest",
"probability")
fpr_svm, tpr_svm, auc_svm, cm_svm = evaluate_model_full(df_svm, "SVM",
"rawPrediction")
fpr_nb, tpr_nb, auc_nb, cm_nb = evaluate_model_full(df_nb, "Naive Bayes",
"probability")
fpr_mlp, tpr_mlp, auc_mlp, cm_mlp = evaluate_model_full(df_mlp, "Neural
Networks", "probability")
fpr_gbt, tpr_gbt, auc_gbt, cm_gbt = evaluate_model_full(df_gbt, "GBT Classifier",

```

```

"probability")
fpr_lr, tpr_lr, auc_lr, cm_lr = evaluate_model_full(df_lr, "Logistic Reg.",
"probability")
fpr_rfu, tpr_rfu, auc_rfu, cm_rfu = evaluate_model_full(df_rf_under, "RF
(Undersampled)", "probability")

# =====
# 1. ΠΙΝΑΚΑΣ ΣΥΓΚΡΙΣΗΣ (Κεφάλαιο 4: Model Evaluation)
# =====
print("\n" + "="*80)
print("ΠΙΝΑΚΑΣ ΣΥΓΚΡΙΣΗΣ ΜΟΝΤΕΛΩΝ (Απαίτηση Εκφώνησης)")
print("="*80)
comparison_df = pd.DataFrame(metrics_dict).round(3)
print(comparison_df.to_string(index=False))
print("="*80)

# =====
# 2. ΟΠΤΙΚΟΠΟΙΗΣΗ 1: CONFUSION MATRICES (Grid)
# =====
fig, axes = plt.subplots(2, 4, figsize=(18, 10))
fig.suptitle('Confusion Matrices (Απαίτηση Εκφώνησης)', fontsize=18,
fontweight='bold')

cms = [cm_rf, cm_svm, cm_nb, cm_mlp, cm_gbt, cm_lr, cm_rfu]
titles = ['Random Forest', 'SVM', 'Naive Bayes', 'Neural Networks', 'GBT
Classifier', 'Logistic Reg.', 'RF (Undersampled)']
colors = ['Blues', 'Oranges', 'Greens', 'Purples', 'Reds', 'YlGnBu', 'coolwarm']

for i in range(7):
    row, col = i // 4, i % 4
    sns.heatmap(cms[i], annot=True, fmt='d', cmap=colors[i], cbar=False,
ax=axes[row, col])
    axes[row, col].set_title(titles[i], fontsize=12)
    axes[row, col].set_xlabel('Predicted')
    axes[row, col].set_ylabel('True')

fig.delaxes(axes[1, 3]) # Αφαίρεση κενού plot
plt.tight_layout()
plt.subplots_adjust(top=0.9)
plt.show()

# =====
# 3. ΟΠΤΙΚΟΠΟΙΗΣΗ 2: ROC CURVES (Απαίτηση Εκφώνησης)
# =====
plt.figure(figsize=(11, 8))
plt.plot(fpr_rf, tpr_rf, label=f'Random Forest (AUC = {auc_rf:.3f})', lw=2)
plt.plot(fpr_svm, tpr_svm, label=f'SVM (AUC = {auc_svm:.3f})', lw=2)

```

```

plt.plot(fpr_nb, tpr_nb, label=f'Naive Bayes (AUC = {auc_nb:.3f})', lw=2)
plt.plot(fpr_mlp, tpr_mlp, label=f'Neural Networks (AUC = {auc_mlp:.3f})', lw=2)
plt.plot(fpr_gbt, tpr_gbt, label=f'GBT (AUC = {auc_gbt:.3f})', lw=2,
linestyle='--')
plt.plot(fpr_lr, tpr_lr, label=f'Logistic Reg. (AUC = {auc_lr:.3f})', lw=2,
linestyle='--')
plt.plot(fpr_rfu, tpr_rfu, label=f'RF Undersampled (AUC = {auc_rfu:.3f})', lw=2,
linestyle=':')
plt.plot([0, 1], [0, 1], 'k--', lw=2, label='Random Chance')
plt.title('Σύγκριση Μοντέλων: Καμπύλη ROC', fontsize=16, fontweight='bold')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate (Recall)')
plt.legend(loc="lower right")
plt.grid(alpha=0.3)
plt.show()

```

```

# =====
# 4. ΟΠΤΙΚΟΠΟΙΗΣΗ 3: ΣΥΓΚΡΙΤΙΚΑ BAR CHARTS (Με F1-Score!)
# =====
# Αφαιρούμε το ROC-AUC από το bar chart για να επικεντρωθούμε καθαρά στις
μετρικές κλάσεων
bar_df = comparison_df.drop(columns=["ROC-AUC"])
metrics_melted = bar_df.melt(id_vars="Model", var_name="Metric",
value_name="Score")

```

```

plt.figure(figsize=(14, 7))
sns.barplot(x='Model', y='Score', hue='Metric', data=metrics_melted,
palette='Dark2')
plt.title('Συγκριτικό Διάγραμμα Μετρικών (Accuracy, Precision, Recall, F1-
Score)', fontsize=16, fontweight='bold')
plt.ylim(0, 1.1)
plt.ylabel('Score')
plt.xticks(rotation=30)
plt.legend(title='Μετρικές', bbox_to_anchor=(1.01, 1), loc='upper left')
plt.grid(axis='y', alpha=0.3)
plt.tight_layout()
plt.show()

```

```

# =====
# ΚΕΦΑΛΑΙΟ 5 & 6: ΣΥΜΠΕΡΑΣΜΑΤΑ & ΠΡΑΚΤΙΚΕΣ ΕΦΑΡΜΟΓΕΣ
# =====
print("\n" + "="*80)
print("ΚΕΦΑΛΑΙΟ 5: ΣΥΓΚΡΙΣΗ ΜΟΝΤΕΛΩΝ")
print("="*80)
print("> Ερώτημα: Ποιο αποδίδει καλύτερα και γιατί;")
print("Απάντηση: Τα αρχικά μοντέλα (SVM, Naive Bayes, MLP) παρουσιάζουν υψηλό
Accuracy ")
print("αλλά αποτυγχάνουν στο F1-Score και στο Recall της Κλάσης 1, λόγω του

```

```

τεράστιου ")
print("class imbalance. Το GBT Classifier και το RF (Undersampled) αποδίδουν
αισθητά ")
print("καλύτερα, διότι θυσιάζουν ελάχιστο από το Accuracy για να μεγιστοποιήσουν
το ")
print("F1-Score και το Recall, διασφαλίζοντας τον εντοπισμό ασθενών σε κίνδυνο.
\n")

print("=*80)
print("ΚΕΦΑΛΑΙΟ 6: ΣΥΜΠΕΡΑΣΜΑΤΑ")
print("=*80)
print("> 1. Insights από τα δεδομένα:")
print("- Η ανάλυση έδειξε ότι τα εγκεφαλικά αποτελούν μόλις το ~5% του
δείγματος.")
print("- Οι κανόνες συσχέτισης ανέδειξαν ότι η ηλικία (>65 ετών) σε συνδυασμό με
")
print(" την υπέρταση ή καρδιακές παθήσεις αποτελούν τον πιο κρίσιμο συνδυασμό.")
print("- Ο K-Means ομαδοποίησε επιτυχώς το δείγμα σε διακριτές ομάδες ρίσκου.\n")

print("> 2. Πρακτικές Εφαρμογές:")
print("- Το σύστημα μπορεί να ενσωματωθεί σε νοσοκομειακά λογισμικά ως εργαλείο
διαλογής (Triage).")
print("- Όταν ο ιατρός εισάγει τα στοιχεία, το GBT ή το Undersampled RF θα ")
print(" κάνει flag τους ασθενείς, θέτοντάς τους σε άμεση προτεραιότητα για
εξετάσεις.")
print("=*80)

```

spark.stop()

Φόρτωση προβλέψεων (Pandas)...

```

===== Random Forest =====
precision    recall  f1-score   support

   Class 0      0.99      0.64      0.78       945
   Class 1      0.10      0.88      0.18        42

 accuracy              0.65       987
macro avg      0.55      0.76      0.48       987
weighted avg   0.95      0.65      0.75       987

```

```

===== SVM =====
precision    recall  f1-score   support

   Class 0      0.99      0.72      0.83       945
   Class 1      0.11      0.79      0.20        42

 accuracy              0.72       987
macro avg      0.55      0.75      0.51       987

```

weighted avg	0.95	0.72	0.81	987
--------------	------	------	------	-----

```
===== Naive Bayes =====
precision    recall  f1-score   support

   Class 0     0.98     0.51     0.67     945
   Class 1     0.06     0.71     0.11      42

 accuracy                   0.51     987
macro avg     0.52     0.61     0.39     987
weighted avg   0.94     0.51     0.64     987
```

```
===== Neural Networks =====
precision    recall  f1-score   support

   Class 0     0.97     0.76     0.85     945
   Class 1     0.08     0.50     0.14      42

 accuracy                   0.75     987
macro avg     0.53     0.63     0.50     987
weighted avg   0.93     0.75     0.82     987
```

```
===== GBT Classifier =====
precision    recall  f1-score   support

   Class 0     0.98     0.75     0.85     945
   Class 1     0.11     0.69     0.19      42

 accuracy                   0.74     987
macro avg     0.55     0.72     0.52     987
weighted avg   0.94     0.74     0.82     987
```

```
===== Logistic Reg. =====
precision    recall  f1-score   support

   Class 0     0.98     0.74     0.84     945
   Class 1     0.11     0.71     0.19      42

 accuracy                   0.74     987
macro avg     0.55     0.73     0.51     987
weighted avg   0.95     0.74     0.81     987
```


```
===== RF (Undersampled) =====
precision    recall  f1-score   support
```

Class 0	0.99	0.65	0.79	945
Class 1	0.10	0.86	0.18	42
accuracy			0.66	987
macro avg	0.54	0.75	0.48	987
weighted avg	0.95	0.66	0.76	987


ΠΙΝΑΚΑΣ ΣΥΓΚΡΙΣΗΣ ΜΟΝΤΕΛΩΝ (Απαίτηση Εκφώνησης)

Model	Acc (Total)	P (Class 0)	R (Class 0)	F1 (Class 0)	P (Class 1)	R (Class 1)	F1 (Class 1)	ROC-AUC
Random Forest	0.652	0.992	0.642	0.780	0.099	0.881	0.177	0.812
SVM	0.724	0.987	0.722	0.834	0.111	0.786	0.195	0.805
Naive Bayes	0.515	0.976	0.506	0.666	0.060	0.714	0.111	0.692
Neural Networks	0.748	0.972	0.759	0.852	0.084	0.500	0.144	0.746
GBT Classifier	0.745	0.982	0.747	0.849	0.108	0.690	0.187	0.790
Logistic Reg.	0.736	0.983	0.737	0.842	0.108	0.714	0.187	0.804
RF (Undersampled)	0.660	0.990	0.651	0.785	0.098	0.857	0.176	0.800


Confusion Matrices (Απαίτηση Εκφώνησης)



Σύγκριση Μοντέλων: Καμπύλη ROC



Συγκριτικό Διάγραμμα Μετρικών (Accuracy, Precision, Recall, F1-Score)



=====

> Ερώτημα: Ποιο αποδίδει καλύτερα και γιατί;
Απάντηση: Τα αρχικά μοντέλα (SVM, Naive Bayes, MLP) παρουσιάζουν υψηλό Accuracy αλλά αποτυγχάνουν στο F1-Score και στο Recall της Κλάσης 1, λόγω του τεράστιου class imbalance. Το GBT Classifier και το RF (Undersampled) αποδίδουν αισθητά καλύτερα, διότι θυσιάζουν ελάχιστο από το Accuracy για να μεγιστοποιήσουν το F1-Score και το Recall, διασφαλίζοντας τον εντοπισμό ασθενών σε κίνδυνο.

=====

ΚΕΦΑΛΑΙΟ 6: ΣΥΜΠΕΡΑΣΜΑΤΑ

=====

- > 1. Insights από τα δεδομένα:
- Η ανάλυση έδειξε ότι τα εγκεφαλικά αποτελούν μόλις το ~5% του δείγματος.
 - Οι κανόνες συσχέτισης ανέδειξαν ότι η ηλικία (>65 ετών) σε συνδυασμό με την υπέρταση ή καρδιακές παθήσεις αποτελούν τον πιο κρίσιμο συνδυασμό.
 - Ο K-Means ομαδοποίησε επιτυχώς το δείγμα σε διακριτές ομάδες ρίσκου.
- > 2. Πρακτικές Εφαρμογές:
- Το σύστημα μπορεί να ενσωματωθεί σε νοσοκομειακά λογισμικά ως εργαλείο διαλογής (Triage).
 - Όταν ο ιατρός εισάγει τα στοιχεία, το GBT ή το Undersampled RF θα κάνει flag τους ασθενείς, θέτοντάς τους σε άμεση προτεραιότητα για εξετάσεις.
- =====