

Φάση A: Data Preprocessing

Υπεύθυνος: Data Engineer

Ακολουθείται το μοτίβο **Bronze** → **Silver** → **Gold** για σταδιακή μετατροπή των ακατέργαστων δεδομένων σε έτοιμα προς μοντελοποίηση feature vectors. Σε κάθε στάδιο τα δεδομένα αποκτούν μεγαλύτερη δομή και καθαρότητα:

- **Bronze:** Ακατέργαστα δεδομένα, φόρτωση από CSV, αφαίρεση περιττών στηλών, καθαρισμός τιμών.
- **Silver:** Καθαρισμένα και κωδικοποιημένα, οι κατηγορικές μεταβλητές αποκτούν αριθμητικούς δείκτες, οι κενές τιμές συμπληρώνονται.
- **Gold:** Έτοιμα για μοντελοποίηση, one-hot encoding, κανονικοποίηση, oversampling.

Όλες οι οπτικοποιήσεις έχουν μεταφερθεί στο EDA notebook.

Βήματα:

1. Bronze Layer, φόρτωση και καθαρισμός
2. Train / Test split
3. Imputation, συμπλήρωση κενών τιμών
4. Silver Layer, categorical encoding
5. SMOTE, αντιμετώπιση class imbalance
6. Gold Layer, one-hot encoding + scaling
7. Αποθήκευση για επόμενα notebooks

1. Εκκίνηση του περιβάλλοντος επεξεργασίας

Η επεξεργασία εκτελείται σε τοπικό περιβάλλον αξιοποιώντας όλους τους διαθέσιμους πυρήνες του μηχανήματος, δεν απαιτείται cluster. Δημιουργείται ο φάκελος data/ όπου θα αποθηκευτούν όλα τα ενδιάμεσα και τελικά αποτελέσματα της προεπεξεργασίας. Η χρήση ενός κεντρικού φακέλου διασφαλίζει ότι τα επόμενα notebooks μπορούν να φορτώσουν τα δεδομένα απ' ευθείας, χωρίς να ξανατρέξουν ολόκληρη τη διαδικασία.

```
import os
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, when, lit
```

```
plt.rcParams['figure.figsize'] = (10, 5)
plt.rcParams['figure.dpi'] = 100
plt.rcParams['font.family'] = 'DejaVu Sans'
```

```
spark = SparkSession.builder \
    .appName("Stroke_DataEngineering") \
    .master("local[*]") \
    .getOrCreate()
```

```
os.makedirs("../data", exist_ok=True)
```

```
print("SparkSession αρχικοποιήθηκε")
```

SparkSession αρχικοποιήθηκε

2. Bronze Layer, πρώτη επαφή με τα ακατέργαστα δεδομένα

Το dataset φορτώνεται από το αρχικό CSV. Η στήλη `id` αφαιρείται αμέσως, είναι τεχνικό αναγνωριστικό χωρίς καμία προγνωστική αξία. Η διατήρησή της θα εισήγαγε θόρυβο και θα μπορούσε να οδηγήσει σε υπερπροσαρμογή.

Η στήλη `bmi` παρουσιάζει ένα ιδιαίτερο πρόβλημα: περιέχει την τιμή `"N/A"` ως string αντί για κενό (`null`). Αυτό σημαίνει ότι κατά την αυτόματη ανίχνευση σχήματος ολόκληρη η στήλη θα αναγνωριστεί ως κείμενο αντί για αριθμητική. Το πρόβλημα διορθώνεται στο επόμενο βήμα με ρητή μετατροπή.

```
df_raw = spark.read.csv("../healthcare-dataset-stroke-data.csv", header=True,
inferSchema=True)
df = df_raw.drop("id")
```

```
bronze_count = df.count()
print(f"Bronze Layer – {bronze_count} γραμμές, {len(df.columns)} στήλες")
```

Bronze Layer – 5110 γραμμές, 11 στήλες

3. Καθαρισμός του BMI

Το string `"N/A"` αντικαθίσταται με πραγματική κενή τιμή (`null`) και η στήλη μετατρέπεται σε αριθμητική μορφή. Από τις 5.110 εγγραφές, οι 201 (3.9%) είχαν ελλιπές BMI.

Κρίσιμη σχεδιαστική επιλογή: η συμπλήρωση των κενών τιμών **δεν** γίνεται τώρα. Αν συμπληρώναμε τις τιμές πριν τον διαχωρισμό `train/test`, θα υπήρχε διαρροή πληροφορίας (`data leakage`), το `test set` θα «έβλεπε» έμμεσα τα στατιστικά του `train`. Το `imputation` θα γίνει αφού το dataset χωριστεί, χρησιμοποιώντας μόνο τα δεδομένα εκπαίδευσης.

```
from pyspark.sql.types import DoubleType
```

```
df = df.withColumn(
    "bmi",
    when(col("bmi") == "N/A", lit(None)).otherwise(col("bmi")).cast(DoubleType())
)
```

```
null_bmi_count = df.filter(col("bmi").isNull()).count()
print(f"Nulls στο bmi: {null_bmi_count} ({(null_bmi_count / bronze_count) *
100:.1f}%)")
```

Nulls στο bmi: 201 (3.9%)

4. Διαχωρισμός σε σύνολα εκπαίδευσης και ελέγχου

Ο διαχωρισμός γίνεται **πριν από οποιονδήποτε μετασχηματισμό**, με αναλογία 80/20. Αυτό είναι θεμελιώδες για την ακεραιότητα του πειράματος: το `test set` λειτουργεί ως προσομοίωση άγνωστων δεδομένων που θα συναντήσει το μοντέλο στην παραγωγή. Κανένα στατιστικό μέτρο,

μετασχηματισμός ή παράμετρος δεν υπολογίζεται από το test, όλα προέρχονται αποκλειστικά από το train.

Η χρήση σταθερού σπόρου τυχαιότητας (seed=42) διασφαλίζει ότι ο διαχωρισμός είναι αναπαραγωγίσιμος, κάθε εκτέλεση του notebook παράγει τα ίδια ακριβώς σύνολα.

```
train, test = df.randomSplit([0.8, 0.2], seed=42)
```

```
train_count = train.count()
test_count = test.count()
print(f"Train: {train_count} | Test: {test_count}")
```

```
Train: 4123 | Test: 987
```

5. Συμπλήρωση ελλυπών τιμών BMI

Οι κενές τιμές του BMI συμπληρώνονται με τη διάμεσο (median), η οποία υπολογίζεται αποκλειστικά από το train set. Η επιλογή της διαμέσου έναντι του μέσου όρου είναι σκόπιμη: η διάμεσος είναι ανθεκτική σε ακραίες τιμές (outliers) και παραμένει αντιπροσωπευτική ακόμα κι αν η κατανομή είναι ασύμμετρη.

Το test set λαμβάνει την ίδια τιμή διαμέσου, η παράμετρος μεταφέρεται από το train χωρίς να επανυπολογιστεί, αποφεύγοντας έτσι τη διαρροή πληροφορίας.

```
from pyspark.ml.feature import Imputer
```

```
imputer = Imputer(inputCols=["bmi"], outputCols=["bmi_imputed"],
strategy="median")
imputer_model = imputer.fit(train)

train =
imputer_model.transform(train).drop("bmi").withColumnRenamed("bmi_imputed",
"bmi")
test = imputer_model.transform(test).drop("bmi").withColumnRenamed("bmi_imputed",
"bmi")
```

```
median_val = imputer_model.surrogateDF.collect()[0][0]
print(f"Median BMI: {median_val:.2f}")
print(f"Nulls after imputation - train:
{train.filter(col('bmi').isNull()).count()}, test:
{test.filter(col('bmi').isNull()).count()}")
```

```
Median BMI: 27.90
```

```
Nulls after imputation - train: 0, test: 0
```

6. Silver Layer, κωδικοποίηση κατηγορικών μεταβλητών

Οι αλγόριθμοι μηχανικής μάθησης απαιτούν αριθμητική είσοδο. Οι πέντε κατηγορικές μεταβλητές (φύλο, οικογενειακή κατάσταση, τύπος εργασίας, τύπος περιοχής, κατάσταση καπνίσματος) μετατρέπονται σε αριθμητικούς δείκτες βάσει της συχνότητας εμφάνισής τους, η πιο συχνή κατηγορία λαμβάνει τον δείκτη 0, η επόμενη τον 1, κ.ο.κ.

Οι αρχικές στήλες με τα string labels διατηρούνται παράλληλα με τους δείκτες. Αυτό επιτρέπει στο EDA notebook να παράγει ευανάγνωστες οπτικοποιήσεις χρησιμοποιώντας τα ονόματα των κατηγοριών αντί για αριθμούς.

Προβλέπεται ειδική μεταχείριση για άγνωστες κατηγορίες: αν το test set περιέχει μια τιμή που δεν εμφανίστηκε στο train, αυτή αντιστοιχίζεται σε ξεχωριστή θέση αντί να απορριφθεί.

```
from pyspark.ml.feature import StringIndexer
from pyspark.ml import Pipeline

cat_cols = ["gender", "ever_married", "work_type", "Residence_type",
"smoking_status"]

indexers = [
    StringIndexer(inputCol=c, outputCol=f"{c}_index", handleInvalid="keep")
    for c in cat_cols
]

idx_pipeline = Pipeline(stages=indexers)
idx_model = idx_pipeline.fit(train)

train = idx_model.transform(train)
test = idx_model.transform(test)

# Αφαίρεση metadata για συμβατότητα με OneHotEncoder
for c in cat_cols:
    ic = f"{c}_index"
    train = train.withColumn(ic, col(ic))
    test = test.withColumn(ic, col(ic))

print("StringIndexer ολοκληρώθηκε")

StringIndexer ολοκληρώθηκε
```

Αποθήκευση Silver Layer

Σε αυτό το σημείο τα δεδομένα είναι πλήρως καθαρισμένα και κωδικοποιημένα: όλες οι κενές τιμές έχουν συμπληρωθεί, οι κατηγορικές μεταβλητές έχουν αριθμητικούς δείκτες, και οι αρχικές ετικέτες διατηρούνται για ευανάγνωστη ανάλυση. Το Silver Layer αποθηκεύεται σε Parquet ώστε το EDA notebook να έχει άμεση πρόσβαση χωρίς να ξανατρέχει τα προηγούμενα βήματα.

```
train.write.mode("overwrite").parquet("../data/train_silver.parquet")
test.write.mode("overwrite").parquet("../data/test_silver.parquet")

print(f"Silver Layer αποθηκεύτηκε - train: {train.count()} γραμμές, test:
{test.count()} γραμμές")

Silver Layer αποθηκεύτηκε - train: 4123 γραμμές, test: 987 γραμμές
```

7. SMOTE, εξισορρόπηση των κλάσεων

Το dataset πάσχει από έντονη ανισορροπία: μόλις το ~5% των ασθενών έχει υποστεί εγκεφαλικό. Ένα μοντέλο που θα προέβλεπε πάντα «όχι stroke» θα πετύχαινε 95% accuracy, αλλά θα ήταν εντελώς άχρηστο στην πράξη.

Το SMOTENC (Synthetic Minority Oversampling Technique for Nominal and Continuous) δημιουργεί συνθετικά παραδείγματα της μειοψηφικής κλάσης. Για τα αριθμητικά χαρακτηριστικά, παράγει ένα νέο σημείο στην ευθεία που συνδέει τον ασθενή με έναν κοντινό γείτονα στον χώρο των χαρακτηριστικών. Για τα κατηγορικά χαρακτηριστικά, αντί για παρεμβολή, επιλέγει την πιο συχνή τιμή (majority vote) μεταξύ των κοντινών γειτόνων. Το αποτέλεσμα είναι ένα ισορροπημένο train set με ίσο αριθμό παραδειγμάτων ανά κλάση.

Η διαδικασία εφαρμόζεται **αποκλειστικά** στο train set. Το test παραμένει ανέγγιχτο με τη φυσική του κατανομή, ώστε η αξιολόγηση να αντικατοπτρίζει πραγματικές συνθήκες. Το SMOTENC τηρεί αυτόματα τους κατηγορικούς δείκτες σε έγκυρες ακέραιες τιμές μέσω majority vote, χωρίς τον κίνδυνο παρεμβολής που δεν έχει νόημα. Το rounding/clipping διατηρείται ως μέτρο ασφαλείας.

```
from imblearn.over_sampling import SMOTENC

numeric_cols = ["age", "hypertension", "heart_disease", "avg_glucose_level",
                "bmi"]
indexed_cols = [f"{c}_index" for c in cat_cols]
features_smote = numeric_cols + indexed_cols

# Μέγιστο έγκυρο index ανά στήλη
idx_stages = idx_model.stages
max_idx = {f"{cat_cols[i]}_index": len(idx_stages[i].labels) - 1 for i in
           range(len(cat_cols))}

train_pdf = train.select(features_smote + ["stroke"]).toPandas()

X_res, y_res = SMOTENC(random_state=42,
                       categorical_features=list(range(len(numeric_cols),
                                                         len(features_smote)))).fit_resample(train_pdf[features_smote],
                                                                 train_pdf["stroke"])

bal_pdf = pd.DataFrame(X_res, columns=features_smote)
bal_pdf["stroke"] = y_res

#for c in indexed_cols:
#    bal_pdf[c] = bal_pdf[c].round().clip(0, max_idx[c])

train_bal = spark.createDataFrame(bal_pdf)

bal_total = train_bal.count()
print(f"Train μετά από SMOTE: {bal_total} δείγματα ({bal_total // 2} ανά κλάση)")

Train μετά από SMOTE: 7832 δείγματα (3916 ανά κλάση)
```

8. Gold Layer, τελική προετοιμασία για μοντελοποίηση

Το Gold Layer είναι το τελικό στάδιο. Εδώ ολοκληρώνονται τρεις κρίσιμοι μετασχηματισμοί:

One-hot encoding: Οι αριθμητικοί δείκτες των κατηγορικών μεταβλητών μετατρέπονται σε δυαδικές στήλες, μία ανά κατηγορία. Χωρίς one-hot encoding, το μοντέλο μπορεί να θεωρήσει λανθασμένα ότι η κατηγορία με δείκτη 3 είναι «μεγαλύτερη» από αυτήν με δείκτη 1 (ordinal bias). Με το one-hot, κάθε κατηγορία είναι ανεξάρτητη δυαδική στήλη.

Συνένωση: Όλες οι δυαδικές και αριθμητικές στήλες συγκεντρώνονται σε ένα ενιαίο διάνυσμα χαρακτηριστικών, το feature vector που θα τροφοδοτήσει τα μοντέλα.

Κανονικοποίηση: Κάθε διάσταση του διανύσματος διαιρείται με την τυπική της απόκλιση. Τα χαρακτηριστικά αποκτούν συγκρίσιμη κλίμακα, απαραίτητο για αλγόριθμους που βασίζονται σε αποστάσεις (π.χ. logistic regression, SVM).

Όλες οι παράμετροι (κατηγορίες one-hot, τυπικές αποκλίσεις) υπολογίζονται αποκλειστικά από το ισορροπημένο train set και εφαρμόζονται και στα δύο σύνολα.

```
from pyspark.sql.types import DoubleType
from pyspark.ml.feature import OneHotEncoder, VectorAssembler, StandardScaler

# Αφαίρεση metadata από το test για συμβατότητα
test = test.select(
    *[col(c) for c in test.columns if not c.endswith("_index")],
    *[col(c).cast(DoubleType()).alias(c) for c in test.columns if
c.endswith("_index")]
)

encoders = [
    OneHotEncoder(inputCol=f"{c}_index", outputCol=f"{c}_vec",
handleInvalid="keep")
    for c in cat_cols
]

assembler = VectorAssembler(
    inputCols=[f"{c}_vec" for c in cat_cols] + numeric_cols,
    outputCol="assembled"
)

scaler = StandardScaler(inputCol="assembled", outputCol="features", withStd=True,
withMean=False)

gold_pipeline = Pipeline(stages=encoders + [assembler, scaler])
gold_model = gold_pipeline.fit(train_bal)

train_gold = gold_model.transform(train_bal).select("features", "stroke")
test_gold = gold_model.transform(test).select("features", "stroke")

print(f"Train Gold: {train_gold.count()} samples")
print(f"Test Gold: {test_gold.count()} samples")
```

Train Gold: 7832 samples

Test Gold: 987 samples

9. Αποθήκευση του Gold Layer

Το τελικό αποτέλεσμα αποθηκεύεται σε Parquet, μια συμπιεσμένη, columnar μορφή αρχείου βελτιστοποιημένη για το Spark. Το Parquet διατηρεί το σχήμα των δεδομένων, επιτρέπει γρήγορη ανάγνωση επιλεγμένων στηλών και μειώνει σημαντικά τον απαιτούμενο χώρο στον δίσκο. Τα επόμενα notebooks φορτώνουν απ' ευθείας από αυτά τα αρχεία χωρίς να ξανατρέχουν ολόκληρη την προεπεξεργασία.

```
train_gold.write.mode("overwrite").parquet("../data/train_gold.parquet")
test_gold.write.mode("overwrite").parquet("../data/test_gold.parquet")

print("Αποθηκεύτηκαν")
```

```
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 95.00% for 8 writers
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 84.44% for 9 writers
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 76.00% for 10 writers
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 69.09% for 11 writers
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 76.00% for 10 writers
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 84.44% for 9 writers
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 95.00% for 8 writers
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 95.00% for 8 writers
26/06/08 20:51:39 WARN MemoryManager: Total allocation exceeds 95.00%
(1,020,054,720 bytes) of heap memory
Scaling row group sizes to 95.00% for 8 writers
```

Αποθηκεύτηκαν

10. Αποθήκευση feature metadata

Για να μπορούν τα επόμενα notebooks να ερμηνεύσουν τις διαστάσεις του feature vector, αποθηκεύουμε την αντιστοίχιση κάθε διάστασης στο όνομα της αρχικής στήλης και στην κατηγορία. Τα labels αντλούνται από τον StringIndexer (idx_model) και τα category sizes από τον

OneHotEncoder (gold_model), καθώς τα Parquet δεν διατηρούν αυτά τα metadata. Το αρχείο είναι απαραίτητο για feature importance, model coefficients και explainability.

```
import json

# Λήψη labels από τον StringIndexer
cat_labels_map = {}
for i, c in enumerate(cat_cols):
    cat_labels_map[c] = list(idx_model.stages[i].labels)

# Λήψη category sizes από τον OneHotEncoder
onehot_sizes = []
for i in range(len(cat_cols)):
    onehot_sizes.append(int(gold_model.stages[i].categorySizes[0]))

# Κατασκευή feature index → στήλη + κατηγορία mapping
feature_map = []
dim = 0
for ci, c in enumerate(cat_cols):
    size = onehot_sizes[ci]
    n_slots = size - 1 # dropLast αφαιρεί την τελευταία
    for j in range(n_slots):
        feature_map.append({
            "index": dim,
            "column": c,
            "category": cat_labels_map[c][j],
            "type": "onehot"
        })
        dim += 1

for nc in numeric_cols:
    feature_map.append({
        "index": dim,
        "column": nc,
        "type": "numeric"
    })
    dim += 1

metadata = {
    "feature_dim": len(feature_map),
    "features": feature_map,
    "cat_labels": cat_labels_map,
    "numeric_cols": numeric_cols,
    "cat_cols": cat_cols
}

with open("../data/feature_metadata.json", "w", encoding="utf-8") as f:
    json.dump(metadata, f, indent=2, ensure_ascii=False)
```



```
print("Feature metadata saved to ../data/feature_metadata.json")
```

```
Feature metadata saved to ../data/feature_metadata.json
```