

## Φάση Δ: Advanced Technique

Εμείς επιλέξαμε το K-Means

```
# =====  
# GLOBAL CONFIGURATION FOR K-MEANS  
# Αλλάξτε αυτή τη μεταβλητή εδώ και θα εφαρμοστεί αυτόματα σε όλο το notebook  
# =====
```

```
SELECTED_K = 5
```

```
print(f"Ορίστηκε καθολικό K = {SELECTED_K}. Έτοιμο για χρήση στα επόμενα κελιά.")
```

Ορίστηκε καθολικό K = 5. Έτοιμο για χρήση στα επόμενα κελιά.

## Εκκίνηση SparkSession & Φόρτωση Δεδομένων

```
from pyspark.sql import SparkSession
```

```
# 1. Εκκίνηση του SparkSession  
spark = SparkSession.builder \  
    .appName("KMeans_Feature_Exploration") \  
    .master("local[*]") \  
    .config("spark.driver.memory", "4g") \  
    .getOrCreate()
```

```
print("SparkSession αρχικοποιήθηκε με επιτυχία.")
```

```
# 2. Φόρτωση των DataFrames  
df_silver = spark.read.parquet("../data/train_silver.parquet")  
train_gold = spark.read.parquet("../data/train_gold.parquet")  
  
print(f"Δεδομένα φορτώθηκαν. Gold Layer σχήμα: {train_gold.schema}")
```

```
WARNING: Using incubator modules: jdk.incubator.vector  
Using Spark's default log4j profile: org/apache/spark/log4j2-defaults.properties  
26/06/12 03:40:48 WARN Utils: Your hostname, cachyos-x8664, resolves to a  
loopback address: 127.0.1.1; using 192.168.1.5 instead (on interface enp4s0)  
26/06/12 03:40:48 WARN Utils: Set SPARK_LOCAL_IP if you need to bind to another  
address  
Using Spark's default log4j profile: org/apache/spark/log4j2-defaults.properties  
Setting default log level to "WARN".  
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use  
setLogLevel(newLevel).  
26/06/12 03:40:48 WARN NativeCodeLoader: Unable to load native-hadoop library for  
your platform... using builtin-java classes where applicable
```

```
SparkSession αρχικοποιήθηκε με επιτυχία.  
Δεδομένα φορτώθηκαν. Gold Layer σχήμα: StructType([StructField('features',  
VectorUDT(), True), StructField('stroke', LongType(), True)])
```

## Εμφάνιση χαρακτηριστικών του Gold Layer

```
import pyspark.sql.functions as F
from pyspark.ml.functions import vector_to_array
from pyspark.sql.types import IntegerType, DoubleType, FloatType, LongType

# 1. Βρούμε τις κατηγορικές στήλες (_index) και εξάγουμε τα labels από τα
Metadata
cat_cols = [field.name for field in df_silver.schema.fields if
field.name.endswith("_index")]
human_categorical_names = []

for col in cat_cols:
    metadata = df_silver.schema[col].metadata
    if "ml_attr" in metadata and "vals" in metadata["ml_attr"]:
        distinct_vals = metadata["ml_attr"]["vals"]
    else:
        original_col_name = col.replace("_index", "")
        distinct_vals = [str(row[0]) for row in
df_silver.select(original_col_name).distinct().sort(col).collect()]

        kept_vals = distinct_vals[:-1]
        original_col_name = col.replace("_index", "")
        for val in kept_vals:
            human_categorical_names.append(f"{original_col_name}_{val}")

# 2. Βρούμε τις αριθμητικές στήλες με τη σωστή σειρά
spark_numeric_types = (IntegerType, DoubleType, FloatType, LongType)
all_numeric_cols = [field.name for field in df_silver.schema.fields if
isinstance(field.dataType, spark_numeric_types)]
numeric_cols = [c for c in all_numeric_cols if c != "stroke" and not
c.endswith("_index")]

# --- ΠΡΟΣΘΗΚΗ: Υπολογισμός Standard Deviations από το df_silver για το Unscaling
---
# Υπολογίζουμε το stddev για κάθε αριθμητική στήλη απευθείας από το Silver layer
stddev_exprs = [F.stddev_samp(F.col(c)).alias(c) for c in numeric_cols]
stds_row = df_silver.select(stddev_exprs).collect()[0]
stds_dict = {c: stds_row[c] for c in numeric_cols}
#
-----

# 3. Ενώνουμε τις λίστες με την ακριβή σειρά που μπήκαν στον VectorAssembler
feature_names = human_categorical_names + numeric_cols
print(f"Συνολικά βρέθηκαν {len(feature_names)} διαστάσεις στο feature vector.")

# 4. Μετατροπή του Vector σε Array στο train_gold
df_look = train_gold.withColumn("features_array", vector_to_array("features"))
```

```
# 5. Χτίζουμε δυναμικά το select expression με ΑΠΟΚΑΝΟΝΙΚΟΠΟΙΗΣΗ (Unscaling)
select_exprs = [F.col("stroke")]
```

```
for i, name in enumerate(feature_names):
    # Αν η στήλη είναι αριθμητική, πολλαπλασιάζουμε με την τυπική απόκλιση
    (Unscaling)
    if name in numeric_cols:
        std_val = stds_dict[name]
        # features_array[i] * std_val
        select_exprs.append((F.col("features_array")[i] *
F.lit(std_val)).alias(name))
    else:
        # Οι κατηγορικές (One-Hot) παραμένουν ως έχουν (0 ή 1)
        select_exprs.append(F.col("features_array")[i].alias(name))
```

```
# 6. Προβολή των 5 πρώτων γραμμών με τις πραγματικές (unscaled) τιμές
df_look.select(select_exprs).show(5, truncate=False)
```

Συνολικά βρέθηκαν 21 διαστάσεις στο feature vector.

```
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
|stroke|gender_Female|gender_Male|gender_Other|ever_married_Yes|ever_married_No|
work_type_Private|work_type_Self-employed|work_type_children|work_type_Govt_job|
work_type_Never_worked|Residence_type_Urban|Residence_type_Rural|
smoking_status_never smoked|smoking_status_Unknown|smoking_status_formerly
smoked|smoking_status_smokes|age                |hypertension|heart_disease|
avg_glucose_level |bmi                |
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
|1      |0.0      |1.0      |0.0      |1.0      |0.0      |
0.0      |1.0      |0.0      |0.0      |0.0      |0.0      |
0.0      |0.0      |1.0      |0.0      |0.0      |
|0.0      |0.0      |1.0      |0.0      |
67.49071599463879|0.0      |0.0      |62.52302496926577 |27.12933431789533
|
|1      |1.0      |0.0      |0.0      |1.0      |0.0      |
1.0      |0.0      |0.0      |0.0      |0.0      |0.0      |
0.0      |0.0      |1.0      |0.0      |
|1.0      |0.0      |0.0      |0.0      |
74.20653415244341|0.0      |0.0      |79.63109651476461 |30.57761455908765
|
|1      |0.0      |1.0      |0.0      |1.0      |0.0      |
```

```

1.0          |0.0          |0.0          |0.0          |
0.0          |0.0          |1.0          |1.0          |
|0.0          |0.0          |0.0          |0.0          |
63.08909881249735|0.0          |0.0          |170.10993881811135|34.9000132882872
|
|1          |0.0          |1.0          |0.0          |1.0          |0.0          |
1.0          |0.0          |0.0          |0.0          |0.0          |0.0          |
0.0          |1.0          |0.0          |0.0          |0.0          |0.0          |
|0.0          |0.0          |1.0          |0.0          |0.0          |0.0          |
64.23912434638792|0.0          |0.0          |60.62988291945089 |33.79799133336316
|
|1          |0.0          |1.0          |0.0          |1.0          |0.0          |
1.0          |0.0          |0.0          |0.0          |0.0          |0.0          |
0.0          |1.0          |0.0          |0.0          |0.0          |0.0          |
|1.0          |0.0          |0.0          |0.0          |0.0          |0.0          |
73.91611278907806|0.0          |0.0          |70.722844095062   |
32.491333621114684|
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
only showing top 5 rows

```

## Εφαρμογή βαρών στο gold για Feature Engineering

```

from pyspark.ml.linalg import Vectors, VectorUDT
import numpy as np
import pyspark.sql.functions as F

# 1. Δημιουργούμε έναν πίνακα με βάρη (αρχικά όλα 1.0) ίσο με το μέγεθος των
features
num_features = len(feature_names)
weights_array = np.ones(num_features)

# --- FEATURE ENGINEERING: ΜΗΔΕΝΙΣΜΟΣ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΓΙΑ ΚΑΛΥΤΕΡΟ PERFORMANCE
---
# Φιλτράρουμε τις στήλες βάσει ονόματος και μηδενίζουμε όσες εισάγουν θόρυβο
for idx, name in enumerate(feature_names):
    if any(demographic in name for demographic in ["gender", "ever_married",
"work_type", "Residence_type", "smoking_status"]):
        weights_array[idx] = 0.0

# Προαιρετικά: Μπορείς να δώσεις ακόμα μεγαλύτερη έμφαση στην ηλικία αν θες (π.χ.
weights_array[feature_names.index("age")] = 2.0)
#
-----

print("=== ΝΕΟΣ ΠΙΝΑΚΑΣ ΒΑΡΩΝ ===")

```

```

for name, weight in zip(feature_names, weights_array):
    print(f"{name}: {weight}")

# 2. UDF για element-wise πολλαπλασιασμό του vector με τα βάρη
apply_weights_udf = F.udf(lambda vec: Vectors.dense(vec.toArray() *
weights_array), VectorUDT())

# 3. Δημιουργία του modified_gold στην μνήμη χωρίς να αλλάξουμε το αρχικό αρχείο
modified_gold = train_gold.withColumn("features", apply_weights_udf("features"))

print("\nΤο modified_gold δημιουργήθηκε με επιτυχία και περιέχει μόνο το ιατρικό
προφίλ των ασθενών!")

=== ΝΕΟΣ ΠΙΝΑΚΑΣ ΒΑΡΩΝ ===
gender_Female: 0.0
gender_Male: 0.0
gender_Other: 0.0
ever_married_Yes: 0.0
ever_married_No: 0.0
work_type_Private: 0.0
work_type_Self-employed: 0.0
work_type_children: 0.0
work_type_Govt_job: 0.0
work_type_Never_worked: 0.0
Residence_type_Urban: 0.0
Residence_type_Rural: 0.0
smoking_status_never smoked: 0.0
smoking_status_Unknown: 0.0
smoking_status_formerly smoked: 0.0
smoking_status_smokes: 0.0
age: 1.0
hypertension: 1.0
heart_disease: 1.0
avg_glucose_level: 1.0
bmi: 1.0

```

Το modified\_gold δημιουργήθηκε με επιτυχία και περιέχει μόνο το ιατρικό προφίλ των ασθενών!

## Elbow Method & Silhouette Score πάνω στο modified\_gold

Μας βοηθάει να επιλέξουμε το σωστό k για το k-Means

```

import matplotlib.pyplot as plt
import pandas as pd
from pyspark.ml.clustering import KMeans
from pyspark.ml.evaluation import ClusteringEvaluator

print("Έναρξη αξιολόγησης του modified_gold...")

# 1. Αρχικοποίηση λιστών για την αποθήκευση των μετρικών

```

```

costs = []
silhouette_scores = []
k_range = range(2, 9) # Δοκιμάζουμε K από 2 έως 8 όπως στην αρχική μελέτη

# 2. Ορισμός του Evaluator για το Silhouette Score
evaluator = ClusteringEvaluator(
    predictionCol="cluster",
    featuresCol="features",
    metricName="silhouette"
)

# 3. Εκτέλεση του Loop για κάθε K
for k_val in k_range:
    print(f"Εκπαίδευση μοντέλου για K = {k_val}...")

    # Ορισμός και εκπαίδευση του KMeans με σταθερό seed για αναπαραγωγιμότητα
    km = KMeans(featuresCol="features", predictionCol="cluster", k=k_val,
seed=42)
    model = km.fit(modified_gold)

    # α) Υπολογισμός Training Cost (WSSSE) για την Elbow Method
    cost = model.summary.trainingCost
    costs.append(cost)

    # β) Παραγωγή προβλέψεων και υπολογισμός Silhouette Score
    predictions = model.transform(modified_gold)
    score = evaluator.evaluate(predictions)
    silhouette_scores.append(score)

    print(f" -> K = {k_val}: WSSSE = {cost:.2f} | Silhouette Score =
{score:.4f}")

# 4. Σχεδίαση Γραφημάτων (Δίπλα-Δίπλα για εύκολη σύγκριση)
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(16, 5))

# Γράφημα 1: Elbow Method
ax1.plot(list(k_range), costs, marker='o', linestyle='--', color='b')
ax1.set_xlabel('Αριθμός Clusters (K)')
ax1.set_ylabel('Training Cost (WSSSE)')
ax1.set_title('Elbow Method (Ψάχνουμε το "σπάσιμο")')
ax1.grid(True)

# Γράφημα 2: Silhouette Score
ax2.plot(list(k_range), silhouette_scores, marker='s', linestyle='--', color='g')
ax2.set_xlabel('Αριθμός Clusters (K)')
ax2.set_ylabel('Silhouette Score')
ax2.set_title('Silhouette Score (Ψάχνουμε το Μέγιστο)')
ax2.grid(True)

```

```
plt.suptitle('Αξιολόγηση K-Means μετά την Εφαρμογή Βαρών (Feature Engineering)',
             fontsize=14, fontweight='bold')
plt.show()
```

Έναρξη αξιολόγησης του modified\_gold...

Εκπαίδευση μοντέλου για K = 2...

-> K = 2: WSSSE = 30879.71 | Silhouette Score = 0.6366

Εκπαίδευση μοντέλου για K = 3...

-> K = 3: WSSSE = 24098.72 | Silhouette Score = 0.3605

Εκπαίδευση μοντέλου για K = 4...

-> K = 4: WSSSE = 22633.74 | Silhouette Score = 0.5431

Εκπαίδευση μοντέλου για K = 5...

-> K = 5: WSSSE = 12183.38 | Silhouette Score = 0.5746

Εκπαίδευση μοντέλου για K = 6...


-> K = 6: WSSSE = 9690.17 | Silhouette Score = 0.5955

Εκπαίδευση μοντέλου για K = 7...

-> K = 7: WSSSE = 8670.86 | Silhouette Score = 0.5368

Εκπαίδευση μοντέλου για K = 8...

-> K = 8: WSSSE = 8104.80 | Silhouette Score = 0.5033



## Ορθή Εφαρμογή PCA σε Train και Test Sets

```
from pyspark.ml.feature import PCA
import pyspark.sql.functions as F

print("Έναρξη διαδικασίας μείωσης διαστασιμότητας με PCA (k=2)...")

# 1. Φόρτωση και του test_gold (αν δεν είναι ήδη φορτωμένο)
test_gold = spark.read.parquet("../data/test_gold.parquet")

# 2. Ορισμός του PCA μοντέλου
# Επιλέγουμε k=2 κυρίως συστατώσεις για να μπορούμε να κάνουμε 2D οπτικοποίηση
pca = PCA(k=2, inputCol="features", outputCol="pca_features")

# 3. ΕΚΠΑΙΔΕΥΣΗ (Fit) ΜΟΝΟ ΣΤΟ TRAIN GOLD
# Υπολογισμός των ιδιοδιανυσμάτων αποκλειστικά από τα δεδομένα εκπαίδευσης
pca_model = pca.fit(train_gold)

# 4. ΜΕΤΑΣΧΗΜΑΤΙΣΜΟΣ (Transform) ΚΑΙ ΣΤΑ ΔΥΟ DATASETS
# Εφαρμόζουμε την ίδια ακριβώς προβολή και στα δύο σύνολα
train_pca = pca_model.transform(train_gold)
test_pca = pca_model.transform(test_gold)

# 5. Επιβεβαίωση αποτελεσμάτων και εμφάνιση δείγματος
print("\n=== TRAIN DATASET ME PCA FEATURES ===")
train_pca.select("stroke", "features", "pca_features").show(3, truncate=True)

print("=== TEST DATASET ME PCA FEATURES ===")
test_pca.select("stroke", "features", "pca_features").show(3, truncate=True)

# Επεξήγηση της διακύμανσης (Explained Variance)
explained_variance = pca_model.explainedVariance
print(f"\nΠοσοστό πληροφορίας που διατηρήθηκε:")
print(f" -> PC1: {explained_variance[0]*100:.2f}%")
print(f" -> PC2: {explained_variance[1]*100:.2f}%")
print(f" -> Συνολική πληροφορία (PC1 + PC2): {sum(explained_variance)*100:.2f}%")

Έναρξη διαδικασίας μείωσης διαστασιμότητας με PCA (k=2)...
```

```
=== TRAIN DATASET ME PCA FEATURES ===
+-----+-----+-----+
|stroke|          features|          pca_features|
+-----+-----+-----+
|      1|(21,[1,3,6,11,15,...]|4.09100954747156...|
|      1|(21,[0,3,5,11,13,...]|4.44356799591138...|
|      1|(21,[1,3,5,11,12,...]|5.65476234798833...|
+-----+-----+-----+
only showing top 3 rows
=== TEST DATASET ME PCA FEATURES ===
+-----+-----+-----+
```



| stroke | features               | pca_features         |
|--------|------------------------|----------------------|
|        | 0 (21,[0,4,7,11,13,... | [1.21718069522327... |
|        | 0 (21,[0,4,7,11,13,... | [1.70074912836987... |
|        | 0 (21,[0,4,7,10,13,... | [1.26885363540631... |

only showing top 3 rows

Ποσοστό πληροφορίας που διατηρήθηκε:

-> PC1: 23.83%  
-> PC2: 13.65%  
-> Συνολική πληροφορία (PC1 + PC2): 37.48%

```
import matplotlib.pyplot as plt
import pandas as pd
from pyspark.ml.clustering import KMeans

print(f"Εκπαίδευση K-Means (K={SELECTED_K}) πάνω στα PCA χαρακτηριστικά...")

# 1. Ορισμός και εκπαίδευση του μοντέλου KMeans στα PCA χαρακτηριστικά του Train set
kmeans_pca = KMeans(featuresCol="pca_features", predictionCol="cluster",
k=SELECTED_K, seed=22390225)
model_pca = kmeans_pca.fit(train_pca)

# 2. Παραγωγή προβλέψεων (Cluster Assignments) για Train και Test
train_preds = model_pca.transform(train_pca)
test_preds = model_pca.transform(test_pca)

# 3. Μετατροπή σε Pandas MONO για τη σχεδίαση των γραφημάτων
plot_train_df = train_preds.select("pca_features", "cluster").toPandas()
plot_test_df = test_preds.select("pca_features", "cluster").toPandas()

# Συνάρτηση για την εξαγωγή των PC1 και PC2 από το Vector σε ξεχωριστές στήλες
Pandas
def extract_pcs(df):
    df['PC1'] = df['pca_features'].apply(lambda vec: float(vec[0]))
    df['PC2'] = df['pca_features'].apply(lambda vec: float(vec[1]))
    return df

plot_train_df = extract_pcs(plot_train_df)
plot_test_df = extract_pcs(plot_test_df)

# 4. Δημιουργία των Γραφημάτων (Δίπλα-Δίπλα)
fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(18, 7))

# ΕΝΗΜΕΡΩΜΕΝΟ: Λεξικό με 5 χρώματα για τα Clusters 0, 1, 2, 3, 4
colors = {
```

```

0: '#1f77b4', # Μπλε
1: '#2ca02c', # Πράσινο
2: '#ff7f0e', # Πορτοκαλί
3: '#d62728', # Κόκκινο
4: '#9467bd'  # Μοβ
}

# Γράφημα A: Train Set Clusters
for cluster_id in sorted(plot_train_df['cluster'].unique()):
    cluster_data = plot_train_df[plot_train_df['cluster'] == cluster_id]
    # Μετατροπή του cluster_id σε απλό int για ασφάλεια με το mapping του dict
    cid_int = int(cluster_id)
    ax1.scatter(
        cluster_data['PC1'], cluster_data['PC2'],
        color=colors.get(cid_int, '#7f7f7f'), alpha=0.5, s=30,
        label=f'Cluster {cid_int}'
    )
ax1.set_xlabel('Principal Component 1 (PC1)')
ax1.set_ylabel('Principal Component 2 (PC2)')
ax1.set_title(f'K-Means Clusters - TRAIN SET (K={SELECTED_K})')
ax1.legend()
ax1.grid(True)


# Γράφημα B: Test Set Clusters (Γενίκευση Μοντέλου)
for cluster_id in sorted(plot_test_df['cluster'].unique()):
    cluster_data = plot_test_df[plot_test_df['cluster'] == cluster_id]
    cid_int = int(cluster_id)
    ax2.scatter(
        cluster_data['PC1'], cluster_data['PC2'],
        color=colors.get(cid_int, '#7f7f7f'), alpha=0.6, s=40, marker='X',
        label=f'Cluster {cid_int}'
    )
ax2.set_xlabel('Principal Component 1 (PC1)')
ax2.set_ylabel('Principal Component 2 (PC2)')
ax2.set_title(f'K-Means Clusters - TEST SET (K={SELECTED_K})')
ax2.legend()
ax2.grid(True)

plt.suptitle(f'Οπτικοποίηση των K-Means Clusters (K={SELECTED_K}) στο Χώρο του
PCA', fontsize=14, fontweight='bold')
plt.show()

Εκπαίδευση K-Means (K=5) πάνω στα PCA χαρακτηριστικά...

```

Οπτικοποίηση των K-Means Clusters (K=5) στο Χώρο του PCA



## Εκπαίδευση στο Train και Πρόβλεψη στο Test Dataset

```
from pyspark.ml.clustering import KMeans
from pyspark.ml.evaluation import ClusteringEvaluator

print(f"Έναρξη εκπαίδευσης του K-Means (K={SELECTED_K}) στο Training Dataset...")

# 1. Ορισμός του μοντέλου K-Means με βάση τις παραμέτρους της ομάδας σας
# Χρησιμοποιούμε k={SELECTED_K} και το συγκεκριμένο seed για σταθερά αποτελέσματα
kmeans = KMeans(featuresCol="features", predictionCol="cluster", k=SELECTED_K,
seed=22390225)

# 2. ΕΚΠΑΙΔΕΥΣΗ (Fit) αποκλειστικά στο Training Dataset
kmeans_model = kmeans.fit(train_gold)
print("Η εκπαίδευση του μοντέλου ολοκληρώθηκε.")

# 3. ΕΦΑΡΜΟΓΗ (Transform) στο Test Dataset για την παραγωγή προβλέψεων
test_preds = kmeans_model.transform(test_gold)
print("Οι προβλέψεις στο Test Dataset δημιουργήθηκαν.")

# 4. ΑΞΙΟΛΟΓΗΣΗ: Υπολογισμός του Silhouette Score στο Test Dataset
evaluator = ClusteringEvaluator(predictionCol="cluster", featuresCol="features",
metricName="silhouette")
test_silhouette = evaluator.evaluate(test_preds)

print("\n===== ΑΠΟΤΕΛΕΣΜΑΤΑ TEST SET =====")
print(f"Silhouette Score στα άγνωστα δεδομένα (Test Set): {test_silhouette:.4f}")

# 5. Εμφάνιση δείγματος των αποτελεσμάτων (Cluster Assignments) μαζί με το
πραγματικό stroke
print("\nΔείγμα προβλέψεων από το Test Set:")
test_preds.select("stroke", "cluster").show(10, truncate=False)
```

Έναρξη εκπαίδευσης του K-Means (K=5) στο Training Dataset...  
Η εκπαίδευση του μοντέλου ολοκληρώθηκε.  
Οι προβλέψεις στο Test Dataset δημιουργήθηκαν.

===== ΑΠΟΤΕΛΕΣΜΑΤΑ TEST SET =====  
Silhouette Score στα άγνωστα δεδομένα (Test Set): 0.2999

Δείγμα προβλέψεων από το Test Set:

```
+-----+-----+
|stroke|cluster|
+-----+-----+
|0      |4      |
|0      |4      |
|0      |4      |
|0      |4      |
|0      |4      |
|0      |4      |
|0      |4      |
|0      |4      |
|0      |4      |
|0      |4      |
+-----+-----+
```

only showing top 10 rows

## Δημιουργία πρόβλεψης και στο train gold και αποθήκευση train & test gold μοντέλου kmeans

```
# =====
# ΣΤΑΔΙΟ: ΑΠΟΘΗΚΕΥΣΗ ΠΡΟΒΛΕΨΕΩΝ CLUSTERS ΓΙΑ CLASSIFICATION
# =====
print("\nΈναρξη παραγωγής και αποθήκευσης των Cluster Predictions...")

# 1. Παράγουμε τις προβλέψεις (cluster assignments) και για το Train Set
train_preds = kmeans_model.transform(train_gold)
print("Οι προβλέψεις για το Training Dataset δημιουργήθηκαν.")

# 2. Αποθήκευση των DataFrames σε Parquet
# Κρατάμε όλες τις αρχικές στήλες (features, stroke) και προσθέτουμε τη στήλη
cluster
train_preds.write.mode("overwrite").parquet("../data/
train_gold_with_cluster.parquet")
test_preds.write.mode("overwrite").parquet("../data/
test_gold_with_cluster.parquet")

print(" -> To train_gold_with_cluster.parquet αποθηκεύτηκε επιτυχώς!")
print(" -> To test_gold_with_cluster.parquet αποθηκεύτηκε επιτυχώς!")
print("\nΌλα έτοιμα! Τα Parquet αρχεία περιλαμβάνουν τη στήλη 'cluster' και είναι
έτοιμα για τα classification μοντέλα.")
```

Έναρξη παραγωγής και αποθήκευσης των Cluster Predictions...

Οι προβλέψεις για το Training Dataset δημιουργήθηκαν.

-> To train\_gold\_with\_cluster.parquet αποθηκεύτηκε επιτυχώς!

-> To test\_gold\_with\_cluster.parquet αποθηκεύτηκε επιτυχώς!

Όλα έτοιμα! Τα Parquet αρχεία περιλαμβάνουν τη στήλη 'cluster' και είναι έτοιμα για τα classification μοντέλα.

## Ποσοστό Stroke Ανα Cluster

# 4. Μετατροπή σε Pandas και υπολογισμός

```
import pandas as pd
pdf_true_test = test_preds.select("cluster", "stroke").toPandas()

print("=====")
print("ΠΡΑΓΜΑΤΙΚΟ TEST: ΠΟΣΟΣΤΟ (%) STROKE ANA CLUSTER")
print("=====")
stroke_profile_test = pdf_true_test.groupby("cluster").mean() * 100
print(stroke_profile_test.round(1).to_string())
```

```
=====
ΠΡΑΓΜΑΤΙΚΟ TEST: ΠΟΣΟΣΤΟ (%) STROKE ANA CLUSTER
=====
```

|         | stroke |
|---------|--------|
| cluster |        |
| 0       | 11.9   |
| 1       | 5.1    |
| 2       | 1.8    |
| 3       | 13.0   |
| 4       | 0.0    |

```
import pandas as pd
import numpy as np
import pyspark.sql.functions as F
```

# 1. Φόρτωση των DataFrames

```
df_silver = spark.read.parquet("../data/train_silver.parquet")
```

# 2. Native PySpark Extraction των Categorical Labels από τα Metadata

```
human_categorical_names = []
cat_cols = [field.name for field in df_silver.schema.fields if
field.name.endswith("_index")]
```

```
for col in cat_cols:
```

```
    # Παίρνουμε τα metadata της στήλης
    metadata = df_silver.schema[col].metadata
```

```
    # Αν η στήλη έχει περάσει από StringIndexer, τα labels υπάρχουν έτοιμα εδώ:
```

```
    if "ml_attr" in metadata and "vals" in metadata["ml_attr"]:
```

```

        distinct_vals = metadata["ml_attr"]["vals"]
    else:
        # Fallback αν δεν υπάρχουν metadata (διαβάζουμε τις τιμές native)
        original_col_name = col.replace("_index", "")
        distinct_vals = [str(row[0]) for row in
df_silver.select(original_col_name).distinct().sort(col).collect()]

    # To OneHotEncoder (dropLast=True) πετάει πάντα την τελευταία τιμή
    kept_vals = distinct_vals[:-1]

    # Φτιάχνουμε τα τελικά ονόματα
    original_col_name = col.replace("_index", "")
    for val in kept_vals:
        human_categorical_names.append(f"{original_col_name}_{val}")

num_cat_features = len(human_categorical_names)

# 3. Μετατροπή των predictions σε Pandas (Μόνο για το τελικό group/report)
pdf_gold = test_preds.select("features", "cluster").toPandas()
features_matrix = np.vstack(pdf_gold['features'].apply(lambda x: x.toArray()))

# 4. Απομόνωση του categorical κομματιού και δημιουργία του DataFrame
cat_features_matrix = features_matrix[:, 0:num_cat_features]
cat_features_binary = (cat_features_matrix > 0.001).astype(int)

pdf_cat_human = pd.DataFrame(cat_features_binary,
columns=human_categorical_names)
pdf_cat_human['cluster'] = pdf_gold['cluster']

# 5. Τελικό Report Ποσοστών
print("\n" + "="*80)
print("=== ΑΝΘΡΩΠΙΝΑ ΠΟΣΟΣΤΑ (%) ΚΑΤΗΓΟΡΙΚΩΝ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΑΝΑ CLUSTER ===")
print("="*80)
cat_profile_human = pdf_cat_human.groupby('cluster').mean() * 100
print(cat_profile_human.round(1).T.to_string())

```

```

=====
=== ΑΝΘΡΩΠΙΝΑ ΠΟΣΟΣΤΑ (%) ΚΑΤΗΓΟΡΙΚΩΝ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΑΝΑ CLUSTER ===
=====

```

| cluster                 | 0    | 1    | 2    | 3    | 4    |
|-------------------------|------|------|------|------|------|
| gender_Female           | 48.3 | 63.1 | 60.7 | 31.5 | 49.2 |
| gender_Male             | 51.7 | 36.9 | 39.3 | 68.5 | 50.8 |
| gender_Other            | 0.0  | 0.0  | 0.0  | 0.0  | 0.0  |
| ever_married_Yes        | 92.4 | 94.9 | 84.8 | 88.9 | 5.0  |
| ever_married_No         | 7.6  | 5.1  | 15.2 | 11.1 | 95.0 |
| work_type_Private       | 51.7 | 58.3 | 71.4 | 55.6 | 44.2 |
| work_type_Self-employed | 27.1 | 24.8 | 12.5 | 27.8 | 3.8  |
| work_type_children      | 0.0  | 0.0  | 0.4  | 1.9  | 45.8 |
| work_type_Govt_job      | 21.2 | 16.9 | 15.6 | 14.8 | 4.6  |

```

work_type_Never_worked      0.0   0.0   0.0   0.0   1.5
Residence_type_Urban        48.3  54.7  54.5  44.4  51.5
Residence_type_Rural        51.7  45.3  45.5  55.6  48.5
smoking_status_never smoked  45.8  41.7  40.6  31.5  23.8
smoking_status_Unknown      18.6  22.1  23.2  18.5  60.0
smoking_status_formerly smoked 21.2  23.9  17.4  27.8   5.0
smoking_status_smokes       14.4  12.4  18.8  22.2  11.2

import pandas as pd
import numpy as np
import pyspark.sql.functions as F
from pyspark.sql.types import IntegerType, DoubleType, FloatType, LongType

# 1. Φόρτωση του Silver DataFrame (για τον υπολογισμό των STDs)
df_silver = spark.read.parquet("../data/train_silver.parquet")

# =====
# ΑΥΤΟΜΑΤΟΣ ΔΙΑΧΩΡΙΣΜΟΣ ΜΕ NATIVE PYSPARK (FIXED)
# =====
spark_numeric_types = (IntegerType, DoubleType, FloatType, LongType)
all_numeric_cols = [field.name for field in df_silver.schema.fields if
isininstance(field.dataType, spark_numeric_types)]

numeric_cols = [c for c in all_numeric_cols if c != "stroke" and not
c.endswith("_index")]
cat_cols = [c for c in all_numeric_cols if c.endswith("_index")]

# 2. Native PySpark Υπολογισμός των STDs (απαραίτητο για το ξε-κανονικοποίηση)
std_exprs = [F.stddev_samp(F.col(c)).alias(c) for c in numeric_cols]
stds_dict = df_silver.select(*std_exprs).first().asDict()

# 3. Εξαγωγή των scaled αριθμητικών χαρακτηριστικών από το Test Προβλέψεων
pdf_gold = test_preds.select("features", "cluster").toPandas()
features_matrix = np.vstack(pdf_gold['features'].apply(lambda x: x.toArray()))

# Βρίσκουμε δυναμικά πού ξεκινούν οι αριθμητικές στήλες στο vector
num_cat_features = features_matrix.shape[1] - len(numeric_cols)
numeric_features_scaled = features_matrix[:, num_cat_features:]

# 4. Δημιουργία DataFrame με τις ΠΡΑΓΜΑΤΙΚΕΣ (Unscaled) τιμές
pdf_numeric_unscaled = pd.DataFrame(columns=numeric_cols)
for i, col in enumerate(numeric_cols):
    pdf_numeric_unscaled[col] = numeric_features_scaled[:, i] * stds_dict[col]

# Προσθήκη της στήλης του cluster
pdf_numeric_unscaled['cluster'] = pdf_gold['cluster']

# 5. Τελικό Report ανά Cluster
print("\n" + "="*90)
print("=== ΣΤΑΤΙΣΤΙΚΟ ΠΡΟΦΙΛ ΠΡΑΓΜΑΤΙΚΩΝ ΑΡΙΘΜΗΤΙΚΩΝ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΑΝΑ CLUSTER")

```

```

===")
print("=*90)

cluster_profiles = pdf_numeric_unscaled.groupby('cluster')
[numeric_cols].agg(['mean', 'min', 'max', 'std'])

for cluster_id in sorted(pdf_numeric_unscaled['cluster'].unique()):
    print(f"\n--- CLUSTER {cluster_id} ---")
    print(cluster_profiles.loc[cluster_id].unstack(level=1).round(2).to_string())

```

```

=====
=== ΣΤΑΤΙΣΤΙΚΟ ΠΡΟΦΙΛ ΠΡΑΓΜΑΤΙΚΩΝ ΑΡΙΘΜΗΤΙΚΩΝ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΑΝΑ CLUSTER ===
=====

```

```

--- CLUSTER 0 ---

```

|                   | mean   | min    | max    | std   |
|-------------------|--------|--------|--------|-------|
| age               | 62.96  | 26.35  | 83.12  | 13.17 |
| hypertension      | 0.27   | 0.00   | 1.01   | 0.45  |
| heart_disease     | 0.00   | 0.00   | 0.00   | 0.00  |
| avg_glucose_level | 171.13 | 109.66 | 216.87 | 21.15 |
| bmi               | 38.47  | 24.96  | 66.06  | 7.90  |

```

--- CLUSTER 1 ---

```

|                   | mean  | min   | max    | std   |
|-------------------|-------|-------|--------|-------|
| age               | 58.58 | 28.38 | 83.12  | 14.23 |
| hypertension      | 0.10  | 0.00  | 1.01   | 0.30  |
| heart_disease     | 0.00  | 0.00  | 0.00   | 0.00  |
| avg_glucose_level | 73.28 | 45.52 | 136.11 | 16.44 |
| bmi               | 31.79 | 13.31 | 43.22  | 4.08  |

```

--- CLUSTER 2 ---

```

|                   | mean  | min   | max    | std   |
|-------------------|-------|-------|--------|-------|
| age               | 43.83 | 13.18 | 82.10  | 12.67 |
| hypertension      | 0.07  | 0.00  | 1.01   | 0.25  |
| heart_disease     | 0.00  | 0.00  | 0.00   | 0.00  |
| avg_glucose_level | 76.12 | 45.62 | 182.31 | 23.75 |
| bmi               | 44.67 | 32.15 | 76.31  | 8.22  |

```

--- CLUSTER 3 ---

```

|                   | mean   | min   | max    | std   |
|-------------------|--------|-------|--------|-------|
| age               | 70.93  | 2.03  | 83.12  | 13.23 |
| hypertension      | 0.24   | 0.00  | 1.01   | 0.44  |
| heart_disease     | 1.05   | 1.05  | 1.05   | 0.00  |
| avg_glucose_level | 110.60 | 46.29 | 221.06 | 56.43 |
| bmi               | 35.14  | 24.38 | 53.81  | 5.27  |

```

--- CLUSTER 4 ---

```

|     | mean  | min  | max   | std   |
|-----|-------|------|-------|-------|
| age | 15.97 | 0.08 | 46.63 | 10.32 |



|                   |       |       |        |       |
|-------------------|-------|-------|--------|-------|
| hypertension      | 0.00  | 0.00  | 1.01   | 0.06  |
| heart_disease     | 0.00  | 0.00  | 0.00   | 0.00  |
| avg_glucose_level | 78.41 | 45.02 | 163.25 | 22.44 |
| bmi               | 26.75 | 15.54 | 40.98  | 5.54  |

```
from pyspark.ml.feature import VectorSlicer
```

```
print("=== ΕΝΑΡΞΗ ΣΤΟΧΕΥΜΕΝΗΣ ΔΙΟΡΘΩΣΗΣ ΠΟΛΥΣΥΓΓΡΑΜΙΚΟΤΗΤΑΣ (OPTIMIZED) ===")
```

```
# 1. Φόρτωση (Όπως το είχα)
```

```
train_gold_clustered = spark.read.parquet("../data/train_gold_with_cluster.parquet")
test_gold_clustered = spark.read.parquet("../data/test_gold_with_cluster.parquet")
```

```
# 2. Οι στήλες που θέλεις να ΠΕΤΑΞΕΙΣ (drop)
```

```
cols_to_drop = [
    "gender_Male", "gender_Other", "ever_married_No",
    "Residence_type_Rural", "work_type_Never_worked",
    "work_type_Govt_job", "smoking_status_Unknown"
]
```

```
# 3. Βρες τα index των στηλών που ΘΕΛΟΥΜΕ ΝΑ ΚΡΑΤΗΣΟΥΜΕ (keep)
```

```
indices_to_keep = [
    idx for idx, name in enumerate(feature_names) if name not in cols_to_drop
]
```

```
print(f"Αρχικά features: {len(feature_names)} -> Τελικά features: {len(indices_to_keep)}")
```

```
# 4. Χρήση του Native VectorSlicer αντί για Python UDF
```

```
slicer = VectorSlicer(
    inputCol="features",
    outputCol="features_filtered",
    indices=indices_to_keep
)
```

```
# Εφαρμογή του μετασχηματισμού
```

```
train_gold_corrected =
slicer.transform(train_gold_clustered).drop("features").withColumnRenamed("features_filtered",
"features")
test_gold_corrected =
slicer.transform(test_gold_clustered).drop("features").withColumnRenamed("features_filtered",
"features")
```

```
# 5. Αποθήκευση (Όπως το είχα)
```

```
train_gold_corrected.write.mode("overwrite").parquet("../data/train_gold_corrected.parquet")
test_gold_corrected.write.mode("overwrite").parquet("../data/test_gold_corrected.parquet")
```

```
print("\nΤα αρχεία αποθηκεύτηκαν επιτυχώς και είναι optimized για SVM/Logistic Regression!")
```

```
=== ΕΝΑΡΞΗ ΣΤΟΧΕΥΜΕΝΗΣ ΔΙΟΡΘΩΣΗΣ ΠΟΛΥΣΥΓΓΡΑΜΙΚΟΤΗΤΑΣ (OPTIMIZED) ===
```

```
Αρχικά features: 21 -> Τελικά features: 14
```

Τα αρχεία αποθηκεύτηκαν επιτυχώς και είναι optimized για SVM/Logistic Regression!

```
import pyspark.sql.functions as F
from pyspark.ml.functions import vector_to_array
```

```
print("=== ΕΛΕΓΧΟΣ ΔΙΟΡΘΩΜΕΝΟΥ DATASET ===")
```

```
# 1. Φόρτωση του νέου διορθωμένου αρχείου
```

```
df_check = spark.read.parquet("../data/train_gold_corrected.parquet")
```

```
# 2. Οι στήλες που αφαιρέθηκαν (για να τις βγάλουμε και από το print)
```

```
cols_to_drop = [
    "gender_Male", "gender_Other", "ever_married_No",
    "Residence_type_Rural", "work_type_Never_worked",
    "work_type_Govt_job", "smoking_status_Unknown"
]
```

```
# 3. Κρατάμε ΜΟΝΟ τα ονόματα των στηλών που υπάρχουν πλέον στο Vector
```

```
active_feature_names = [name for name in feature_names if name not in
    cols_to_drop]
```

```
# 4. Μετατροπή Vector σε Array
```

```
df_look = df_check.withColumn("features_array", vector_to_array("features"))
```

```
# 5. Χτίζουμε δυναμικά το select expression με τη ΣΩΣΤΗ λίστα στηλών
```

```
select_exprs = [F.col("stroke"), F.col("cluster")]
for i, name in enumerate(active_feature_names):
    select_exprs.append(F.col("features_array")[i].alias(name))
```

```
# 6. Προβολή των πρώτων 5 γραμμών
```

```
print(f"Συνολικό σχήμα: {df_check.count()} γραμμές")
print(f"Αρχική Διάσταση Vector: {len(feature_names)} -> Νέα Διάσταση: {len(active_feature_names)}")
print("Οι στήλες που αφαιρέθηκαν δεν υπάρχουν καν στο vector πλέον (κέρδος σε μνήμη/ταχύτητα):\n")
```

```
df_look.select(select_exprs).show(5, truncate=False)
```

```
=== ΕΛΕΓΧΟΣ ΔΙΟΡΘΩΜΕΝΟΥ DATASET ===
```

```
Συνολικό σχήμα: 7832 γραμμές
```

```
Αρχική Διάσταση Vector: 21 -> Νέα Διάσταση: 14
```

```
Οι στήλες που αφαιρέθηκαν δεν υπάρχουν καν στο vector πλέον (κέρδος σε μνήμη/ταχύτητα):
```

```

+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+
|stroke|cluster|gender_Female|ever_married_Yes|work_type_Private|work_type_Self-
employed|work_type_children|Residence_type_Urban|smoking_status_never smoked|
smoking_status_formerly smoked|smoking_status_smokes|age          |
hypertension|heart_disease|avg_glucose_level |bmi              |
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+
|1      |1      |0.0      |1.0      |0.0      |1.0
|0.0      |0.0      |0.0      |0.0      |0.0      |0.0
|1.0      |2.9835557556544465|0.0      |0.0      |
1.4067102005010215|3.520133234281628|
|1      |1      |1.0      |1.0      |1.0      |0.0
|0.0      |0.0      |0.0      |0.0      |0.0      |0.0
|0.0      |3.2804412994415104|0.0      |0.0      |
1.7916259777812247|3.96756057385077 |
|1      |0      |0.0      |1.0      |1.0      |0.0
|0.0      |0.0      |1.0      |0.0      |0.0      |0.0
|0.0      |2.7889738774742123|0.0      |0.0      |
3.827316196867818 |4.528408077154065|
|1      |1      |0.0      |1.0      |1.0      |0.0
|0.0      |1.0      |0.0      |0.0      |0.0      |0.0
|1.0      |2.8398129484519354|0.0      |0.0      |
1.3641162563695421|4.385416580828362|
|1      |1      |0.0      |1.0      |1.0      |0.0
|0.0      |1.0      |0.0      |0.0      |0.0      |0.0
|0.0      |3.2676026694542015|0.0      |0.0      |
1.5911985423909258|4.215872824803275|
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+-----+-----+-----+-----+-----+
+-----+
only showing top 5 rows

```